# MACHINE LEARNING CANVAS

Designed for: Mi Bici | Designed by: Eduardo Sebastián Vela Alanís | Date: 18/10/2026 | Iteration: 1

## PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

**1. What is the type of task?** El proyecto contempla tres tareas de aprendizaje automático: regresión, clasificación y agrupamiento. El modelo de regresión buscará predecir la cantidad de viajes que se iniciarán en cada estación durante el día siguiente, mientras que el modelo de clasificación estimará el nivel de riesgo de que una estación se quede sin bicicletas o sin anclajes disponibles. Por último, el modelo de agrupamiento identificará estaciones con patrones de uso similares a partir de sus datos históricos, sin necesidad de predecir un resultado futuro.

**2. Which entity are predictions made on?** La entidad principal sobre la que se realizarán las predicciones será cada estación del sistema MiBici. Para los modelos de regresión y clasificación, se utilizará una granularidad diaria, por lo que cada predicción corresponderá a una estación específica durante el día siguiente. En el caso del modelo de agrupamiento, se analizará el comportamiento histórico de cada estación para identificar aquellas que comparten patrones de uso similares.

**3. What are the possible outcomes to predict?** Los resultados dependerán del tipo de modelo utilizado. El modelo de regresión generará un valor numérico que representará la cantidad estimada de viajes que se iniciarán en una estación durante el día siguiente. El modelo de clasificación asignará una de tres categorías: riesgo de quedarse sin bicicletas, riesgo bajo según el balance de viajes o riesgo de quedarse sin anclajes disponibles. Estas categorías se determinarán a partir del balance entre viajes iniciados y finalizados, normalizado según la capacidad de cada estación. Finalmente, el modelo de agrupamiento identificará grupos de estaciones con características de uso similares, sin utilizar una variable objetivo previamente definida.

## DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

Las predicciones generadas por los modelos permitirán a los equipos de operaciones, logística y planeación de MiBici tomar decisiones informadas sobre la distribución de bicicletas y la gestión de las estaciones. El modelo de regresión estimará la cantidad de viajes que se iniciarán en cada estación durante el día siguiente, permitiendo anticipar la demanda y planificar la distribución de bicicletas. Por otro lado, el modelo de clasificación identificará las estaciones con mayor riesgo de quedarse sin bicicletas o sin anclajes disponibles, utilizando como referencia el balance entre viajes iniciados y finalizados, así como la capacidad de cada estación. Esto permitirá priorizar las estaciones que requieren operaciones de rebalanceo. Finalmente, el modelo de agrupamiento identificará estaciones con patrones de uso similares, considerando su comportamiento histórico y distribución geográfica, lo que facilitará la identificación de zonas con necesidades operativas semejantes y la toma de decisiones estratégicas sobre la capacidad de las estaciones. En conjunto, estos resultados permitirán mejorar la planificación de recursos y la eficiencia operativa del sistema MiBici.

## VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

**1. Who is the end beneficiary, and what specific pain points are addressed?** Los principales beneficiarios de este proyecto serán los equipos de operaciones, logística y planeación de MiBici, así como los usuarios del sistema. Mediante el desarrollo de modelos de regresión, clasificación y agrupamiento, se busca facilitar la toma de decisiones relacionadas con la distribución de bicicletas y la gestión de las estaciones. El modelo de regresión permitirá anticipar la demanda diaria de viajes en cada estación, mientras que el modelo de clasificación ayudará a identificar aquellas con mayor riesgo estimado de quedarse sin bicicletas o anclajes disponibles. Por otro lado, el modelo de agrupamiento permitirá identificar estaciones con patrones de uso similares y analizar su distribución geográfica, facilitando la identificación de zonas con necesidades operativas semejantes. En conjunto, estos modelos contribuirán a una mejor planificación de recursos, un rebalanceo más eficiente y una mayor disponibilidad de bicicletas y anclajes, con el objetivo de mejorar la experiencia de los usuarios del sistema.

**2. How will the ML solution integrate with their workflow, and through which user interfaces?** Los resultados generados por los modelos estarán disponibles mediante una API, lo que permitirá que los sistemas de MiBici los consulten e integren en sus operaciones. De esta manera, los usuarios finales podrán acceder a la información a través de las aplicaciones y servicios del sistema.

## DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

**1. How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?** Los datos utilizados para entrenar los modelos se descargan del sitio oficial de MiBici. La idea es utilizar siempre un año de información para el entrenamiento, por lo que, cuando esté disponible un nuevo mes de datos, se descargará y se volverán a entrenar los modelos, utilizando únicamente los 12 meses más recientes. De esta manera, los modelos se mantendrán actualizados con los patrones temporales más recientes del sistema MiBici.

**2. What strategies are in place to update data continuously while controlling cost and maintaining freshness?** Antes de utilizar los datos para entrenar los modelos, se realizará un proceso de limpieza y preparación de la información. Este proceso incluirá la identificación y eliminación de valores nulos, registros duplicados y datos con fechas o identificadores de estaciones inconsistentes. Posteriormente, los datos se agruparán por estación y día para obtener el número de viajes diarios de cada estación. Además, se excluirá cualquier información personal de los usuarios, ya que no es necesaria para el entrenamiento de los modelos.

## DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Los datos que utilizamos provienen del sitio oficial de Mi Bici:
https://mibici.net/es/datos-abiertos/

Se usan los datos de la nomenclatura de estaciones de MiBici, y los datos históricos de octubre del 2025 a septiembre del 2026.

**4. When are outcomes observed?** Para los modelos de regresión y clasificación, el horizonte de predicción será de un día. Esto significa que los modelos utilizarán información histórica para estimar el comportamiento de cada estación durante el día siguiente. Una vez finalizado ese día y disponibles los registros correspondientes, será posible conocer la cantidad real de viajes iniciados y calcular el balance de viajes de cada estación para evaluar las predicciones. Es importante mencionar que, debido a que los datos no incluyen el inventario real de bicicletas, las categorías de riesgo serán aproximaciones calculadas a partir del balance de viajes y la capacidad de las estaciones. Por otro lado, el modelo de agrupamiento no tendrá un horizonte de predicción, ya que utilizará datos históricos para identificar grupos de estaciones con comportamientos similares.

## IMPACT SIMULATION



What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

**1. What are the cost/gain values for (in)correct decisions?** Por el momento, no se han establecido valores monetarios específicos para evaluar los costos y beneficios de las decisiones tomadas a partir de los modelos. Sin embargo, una predicción correcta de la demanda o del riesgo de disponibilidad permitiría mejorar la distribución de bicicletas, reducir los viajes innecesarios de rebalanceo y aumentar la disponibilidad del servicio para los usuarios. Por otro lado, las predicciones incorrectas podrían provocar una distribución ineficiente de los recursos. Por ejemplo, sobreestimar la demanda de una estación podría ocasionar el traslado innecesario de bicicletas, mientras que subestimarla podría provocar que no haya suficientes bicicletas disponibles. En el futuro, estos costos y beneficios podrían cuantificarse considerando factores como el costo operativo del rebalanceo, la cantidad de viajes no atendidos y la disponibilidad del

## MAKING PREDICTIONS



Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

**1. Are predictions made in batch or in real time?** Se propone realizar las predicciones mediante procesamiento por lotes (*batch processing*), ya que los modelos de regresión y clasificación tienen un horizonte de predicción de un día y no requieren generar resultados en tiempo real. Este enfoque permitirá procesar la información disponible de todas las estaciones y generar sus predicciones de manera conjunta. Por otro lado, el modelo de agrupamiento se ejecutará periódicamente para identificar cambios en los patrones de uso de las estaciones. Los resultados generados por los tres modelos estarán disponibles mediante una API, permitiendo que los sistemas de MiBici los consulten sin necesidad de ejecutar los modelos cada vez que se solicite información.

**2. How frequently?** Se propone ejecutar los modelos de regresión y clasificación diariamente, con el objetivo de generar predicciones para el día siguiente en cada estación de MiBici. En cambio, el modelo de agrupamiento podrá ejecutarse

## BUILDING MODELS



How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

**1. How many models are needed in production?** Se contempla utilizar tres modelos de aprendizaje automático en producción, uno para cada problema definido en el proyecto: regresión, clasificación y agrupamiento. El modelo de regresión permitirá predecir la cantidad de viajes que se iniciarán en cada estación durante el día siguiente, mientras que el modelo de clasificación estimará el riesgo de que una estación se quede sin bicicletas o sin anclajes disponibles. Por último, el modelo de agrupamiento identificará estaciones con patrones de uso similares para facilitar la planificación operativa. Para cada tarea, se seleccionará el modelo que presente el mejor desempeño durante la etapa de evaluación.

**2. When should they be updated?** Los modelos se actualizarán mensualmente, conforme MiBici publique nuevos datos de viajes en su plataforma oficial. Para el entrenamiento se utilizará una ventana móvil de 12 meses, de manera que, cuando esté disponible un nuevo mes de

## FEATURES



What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

**1. What representations are used for entities at prediction time?** Para realizar las predicciones, cada estación de MiBici será representada mediante un conjunto de características construidas a partir de sus datos históricos. En el caso del modelo de regresión, se utilizarán variables temporales, como el día de la semana, el mes y la identificación de fines de semana, además de información histórica, como la cantidad de viajes del día anterior, los viajes registrados siete días antes y los promedios móviles de los últimos siete días. Para el modelo de clasificación, se utilizarán características similares, incorporando también la cantidad de viajes iniciados y finalizados, el balance histórico de viajes y la capacidad de cada estación. Por último, el modelo de agrupamiento representará cada estación mediante indicadores de su comportamiento histórico, como el promedio diario de viajes, la proporción de viajes realizados durante los fines de semana, la distribución de viajes por periodos del día y la variabilidad de la demanda. A diferencia de los otros modelos, el agrupamiento no realizará predicciones para el día siguiente, sino que identificará estaciones con patrones

servicio.

**2. Which data is used to simulate pre-deployment impact?** Para evaluar el impacto potencial de los modelos antes de su despliegue, se utilizarán los datos históricos de viajes de MiBici, correspondientes al periodo de octubre de 2025 a septiembre de 2026. Se empleará una división cronológica de los datos, destinando aproximadamente el 70 % al entrenamiento, el 15 % a la validación y el 15 % a las pruebas. Esto permitirá evaluar las predicciones utilizando información posterior a la empleada durante el entrenamiento, simulando el comportamiento de los modelos frente a datos futuros. Para estimar su impacto operativo, se podrán comparar las predicciones con los viajes realmente registrados y analizar qué estaciones habrían sido priorizadas para operaciones de rebalanceo. Sin embargo, debido a que no se cuenta con información del inventario real de bicicletas ni con los costos operativos, la evaluación del impacto será aproximada y no permitirá determinar con exactitud los beneficios económicos de implementar los modelos.

**3. What are the criteria for deployment?** Los modelos podrán considerarse para su despliegue una vez que demuestren un desempeño satisfactorio durante las pruebas y superen los resultados de sus respectivos modelos de referencia (*baselines*). Para el modelo de regresión, se evaluarán métricas como el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE), buscando minimizar las diferencias entre los viajes predichos y los reales. Para el modelo de clasificación, se utilizarán métricas como F1-score, recall y la matriz de confusión, prestando especial atención a la identificación correcta de estaciones con riesgo elevado. Finalmente, para el modelo de agrupamiento, se utilizarán métricas como el coeficiente de silueta y el índice Davies-Bouldin, además de evaluar si los grupos identificados tienen una interpretación útil para las operaciones de MiBici. Adicionalmente, se verificará que los

mensualmente, debido a que su objetivo es identificar patrones históricos de uso y no realizar predicciones diarias. Además, los tres modelos se reentrenarán mensualmente, conforme MiBici publique nuevos datos, utilizando una ventana móvil de los 12 meses más recientes. De esta manera, los modelos podrán adaptarse a los cambios en los patrones de uso del sistema.

**3. How much time is available for this (including featurization and decisions)?** Debido a que las predicciones de regresión y clasificación corresponden al día siguiente, se propone que el procesamiento de los datos, la generación de características y la ejecución de los modelos se completen antes del inicio del día que se desea predecir. Esto permitirá que los equipos de operaciones y logística de MiBici tengan acceso anticipado a los resultados y puedan utilizarlos para planificar la distribución de bicicletas. Por el momento, no se ha establecido un límite de tiempo específico para estos procesos, por lo que será necesario evaluar su duración durante el desarrollo del proyecto. En el caso del agrupamiento, los tiempos de ejecución podrán ser más flexibles, ya que sus resultados estarán orientados principalmente a la planificación estratégica.

**4. Which computational resources are used?** Se propone utilizar principalmente recursos de CPU para ejecutar los procesos de limpieza, ingeniería de características e inferencia de los modelos. Debido a que las predicciones se realizarán mediante procesamiento por lotes y con una granularidad diaria, inicialmente no se considera necesario utilizar recursos especializados, como GPU. Para producción, se contempla utilizar un servidor que permita ejecutar periódicamente los modelos, almacenar sus resultados y ponerlos a disposición mediante una API. Sin embargo, todavía no se han definido los requisitos específicos de CPU, memoria RAM y almacenamiento, por lo que estos se determinarán a partir de las pruebas de rendimiento realizadas durante el desarrollo del proyecto.

información, se descarguen y procesen sus datos, se descarte el mes más antiguo y se vuelvan a entrenar los modelos utilizando el año de información más reciente. Esto permitirá que los modelos incorporen los patrones temporales más actuales del sistema y se adapten a posibles cambios en el comportamiento de los usuarios, como el crecimiento del número de estaciones.

**3. How much time is available for this (including featurization and analysis)?** Debido a que los modelos de regresión y clasificación realizarán predicciones con un horizonte de un día, el procesamiento de los datos, la generación de características y la ejecución de las predicciones deberán completarse antes del inicio del día que se desea predecir. Por otro lado, el reentrenamiento de los modelos y la actualización de los grupos de estaciones podrán realizarse como procesos independientes cuando se publiquen nuevos datos mensuales. Por el momento, no se ha establecido un límite de tiempo específico para estos procesos, por lo que será necesario medir su duración durante el desarrollo del proyecto para definir los tiempos máximos de ejecución.

**4. Which computation resources are used?** Se propone utilizar recursos computacionales basados principalmente en CPU para realizar la limpieza de datos, la ingeniería de características, el entrenamiento y la ejecución de los modelos. Durante el desarrollo, estos procesos podrán realizarse en un entorno de Python utilizando bibliotecas de aprendizaje automático como Scikit-learn y LightGBM. Para producción, se contempla utilizar un servidor que permita ejecutar los modelos y exponer sus resultados mediante una API, facilitando su integración con los sistemas de MiBici. Los requisitos específicos de procesamiento, memoria y almacenamiento se determinarán posteriormente, a partir del desempeño y los tiempos de ejecución observados durante las pruebas.

de uso similares.

**2. What aggregations or transformations are applied to raw data sources?** Antes de utilizar los datos para entrenar los modelos, se realizará un proceso de limpieza y transformación de la información. Inicialmente, se identificarán y tratarán los valores nulos, registros duplicados, fechas inconsistentes e identificadores de estaciones inválidos. Posteriormente, se convertirán las fechas a formatos adecuados y se relacionarán los registros de viajes con la información de las estaciones para incorporar características como su ubicación geográfica y capacidad. Para los modelos de regresión y clasificación, los viajes se agruparán por estación y día, calculando la cantidad de viajes iniciados y finalizados diariamente. En el caso de clasificación, también se calculará el balance neto de viajes, normalizado según la capacidad de cada estación, para construir las categorías de riesgo. Para el modelo de agrupamiento, se calcularán indicadores históricos que describan el comportamiento general de cada estación y se normalizarán o estandarizarán las variables para evitar que las diferencias de escala afecten la formación de los grupos. Finalmente, se excluirán los datos personales que no sean necesarios para el proyecto y se garantizará que las variables utilizadas para realizar predicciones se construyan únicamente con información disponible antes del periodo que se desea predecir.

modelos puedan ejecutarse dentro de los tiempos requeridos y que sus resultados puedan consultarse correctamente mediante la API. Los umbrales mínimos de desempeño se definirán después de evaluar los primeros modelos.

**4. Are there fairness constraints?** Por el momento, no se han establecido restricciones formales de equidad (*fairness*) para los modelos. Sin embargo, debido a que sus resultados podrían utilizarse para tomar decisiones sobre la distribución de bicicletas, será importante evitar que estas decisiones perjudiquen sistemáticamente a determinadas estaciones o zonas de la ciudad. Por ejemplo, una estación con menor demanda no necesariamente debería recibir menos atención, ya que esto podría reducir la disponibilidad del servicio para sus usuarios. Para evaluar este aspecto, se propone analizar el desempeño de los modelos en diferentes estaciones y zonas geográficas, buscando identificar diferencias significativas en la precisión de las predicciones o en las recomendaciones generadas. Además, se excluirán los datos personales y las variables demográficas que no sean necesarias para el proyecto, con el objetivo de proteger la privacidad de los usuarios.

## MONITORING

**How will model performance be monitored, and which KPIs will be used?** El desempeño de los modelos se monitoreará periódicamente mediante la comparación de sus resultados con los datos reales publicados por MiBici. Para el modelo de regresión, se utilizarán métricas como el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE), con el objetivo de evaluar la precisión de las predicciones de demanda. Para el modelo de clasificación, se utilizarán el F1-score, el recall de las categorías de riesgo y la matriz de confusión, prestando especial atención a la identificación de estaciones que podrían presentar problemas de disponibilidad. Por último, para el modelo de agrupamiento, se utilizarán el coeficiente de silueta y el índice Davies-Bouldin, además de analizar si los grupos identificados mantienen patrones de uso similares a lo largo del tiempo. Se propone revisar estas métricas mensualmente, conforme se publiquen nuevos datos, comparándolas con los resultados obtenidos durante el entrenamiento y la evaluación. Adicionalmente, se monitorearán posibles cambios en la distribución de los datos y en los patrones temporales del sistema para detectar una degradación en el desempeño de los modelos. Si se identifica una disminución significativa en su rendimiento, se evaluará la necesidad de actualizar los modelos o modificar sus características.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

# What your canvas is for

A filled canvas does 4 jobs, and each one needs certain boxes filled in with care.

- **Deciding what's worth building.** Put each idea on its own canvas and you can compare the ideas on the same terms: what each could gain in a year, and whether the outcomes a model would learn from were ever recorded. That takes dollar amounts in the Impact Simulation box, and a named person in the Value Proposition box who acts on each prediction.
- **Agreeing on what gets built.** Some of the choices that set a system's value look technical, but they're business decisions. What counts as a lost customer: 60 days without buying, or 90? How far ahead do you predict? How many flagged cases can your team act on? On the canvas, business, data and engineering make these choices together, instead of leaving them to whoever writes the code.
- **Knowing when the model is good enough.** The Impact Simulation box sets the performance the model has to reach to pay off. Test the model on enough of the cases you're predicting: 35,000 machine-hours of data can hold just 3 failures, too few to measure anything.
- **Learning after launch.** If acting on a prediction changes the outcome, keep a small share of flagged cases untouched and record that share in the Decisions box, so you can see what your action changed.

Whatever you can't answer is the work left before anyone writes code.

*"The Canvas allowed us to structure and focus our delivery sprints. The ML system went live in June 2020 and still is."*
— Christian Schiller, Senior IT & Enterprise Architect, Deutsche Telekom

**Book a project review**

Louis Dorard created the canvas in 2015. Book a free 30-minute call, then send him your canvas draft, or a few lines about the project if you haven't started one. He prepares the call from what you send, and you'll leave knowing where the project is likely to break, and what to check before anyone builds it.

**Book a 30-minute call →**

**Reference the Machine Learning Canvas**

If you need to reference the Canvas formally (e.g. in documentation or publications), you may use:

```
@misc{mlc,
  title  = "Machine Learning Canvas",
  author = "Louis Dorard (OWNML)",
  url    = "https://www.ownml.co/",
  year   = "2015"
}
```

*"MLC played an essential role in a positive project outcome. It is now being used throughout the organization."*
— Daitan, now part of Coforge, a global IT services firm